Année scolaire
2026 - 2027

Chapitre 1

Introduction au Machine Learning et démarche expérimentale

Problème réel → données → apprentissage → généralisation

Enseignante :

Dr. Ing. Ones Sidhom

Ambassadrice NVIDIA & Instructrice Certifiée

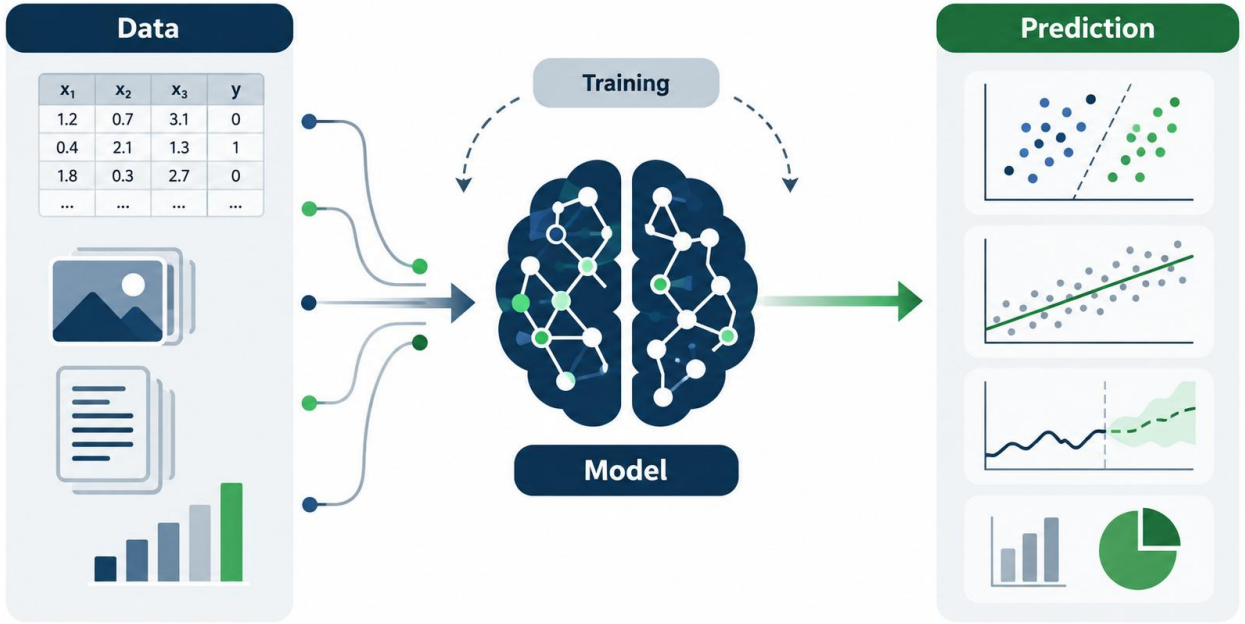
Enseignante-Chercheuse en IA & Science des Données

Définition du Machine Learning

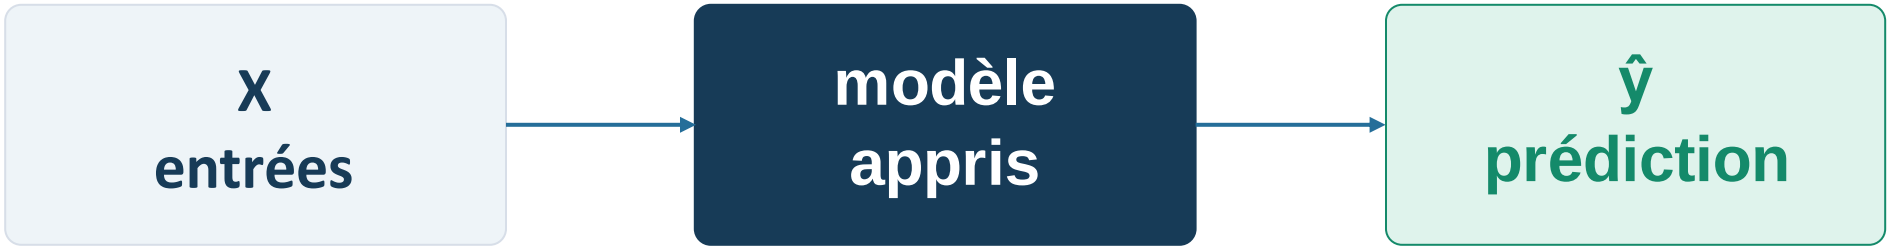
Un système apprend à améliorer son comportement à partir d'exemples.

Définition plus formelle

Le Machine Learning est une approche de l'IA qui permet à un système d'**apprendre automatiquement** à partir de **données** afin de produire des **prédictions** ou des décisions sur de **nouveaux exemples**.



Entrées, modèle et prédiction



On souhaite que ŷ soit proche de y.

X

données d'entrée utilisées par le modèle

y

vérité terrain ou cible réelle

ŷ

sortie produite par le modèle

Modèle

fonction apprise à partir des exemples

Anatomie d'un dataset

Patient	Âge	Taille tumeur	Texture	Classe
P1	45	1,8	0,42	Bénigne
P2	63	4,7	0,81	Maligne
P3	38	1,2	0,35	Bénigne
P4	57	3,9	0,70	Maligne

Lignes instances

Colonnes d'entrée features

Dernière colonne label

Instance, features et label

Une ligne = une instance

Patient	Âge	Taille tumeur	Texture	Classe
P2	63	4,7	0,81	Maligne

features | label

Le modèle reçoit les features et apprend à prédire le label.

Matrice X et vecteur y

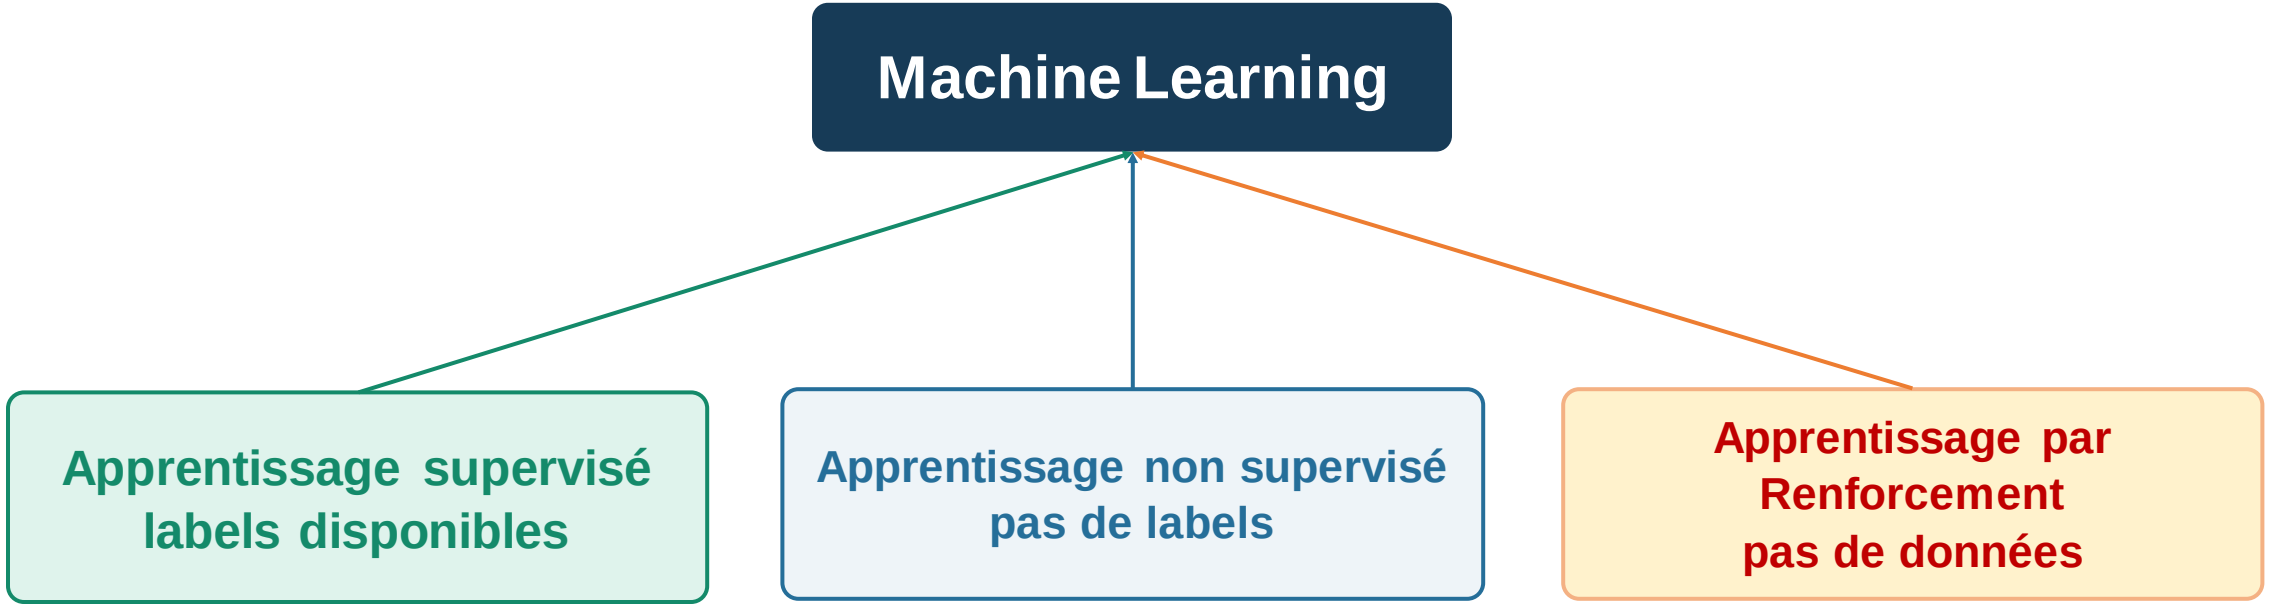
Âge	Taille	Texture
45	1,8	0,42
63	4,7	0,81
38	1,2	0,35
57	3,9	0,70

X

Classe
Bénigne
Maligne
Bénigne
Maligne

y

Grandes familles d'apprentissage



Apprentissage supervisé

Dans l'apprentissage supervisé, le modèle est entraîné sur un ensemble de données étiqueté, où chaque exemple de données est associé à une sortie connue.

Nous disposons de couples connus.

X: Email	→	y: Spam
X: Image médicale	→	y: Maligne
X: Surface maison	→	y: Prix
X: Transaction	→	y: Fraude

Le modèle apprend le lien entre les entrées et la sortie.

Le **label** sert de **référence** pour calculer **l'erreur** pendant l'apprentissage.

Classification



La sortie appartient à un ensemble fini de catégories.

Binaire

Spam / Non spam
Maligne / Bénigne

Multiclasse

Chiffre 0, 1, 2... 9
Type de document

Classification binaire : règle de seuil

- En classification binaire, on considère généralement les échantillons marqués avec l'étiquette **0** comme appartenant à la **classe négative**, tandis que ceux marqués avec l'étiquette **1** sont considérés comme appartenant à la **classe positive**.
- Dans la classification **binaire**, la décision quant à l'appartenance à une classe est généralement basée sur **une règle de seuil** appliquée à une mesure de confiance ou de probabilité.
- Si la mesure **dépasse** un certain seuil, l'instance est attribuée à la classe **positive** ; **sinon**, elle est attribuée à la classe **négative**.

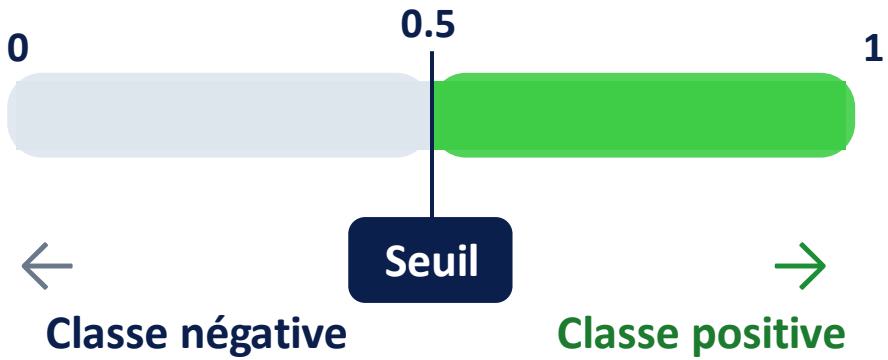
Classification binaire : règle de seuil

Les deux classes

0 — **Étiquette 0**
Classe négative

1 — **Étiquette 1**
Classe positive

Score / probabilité

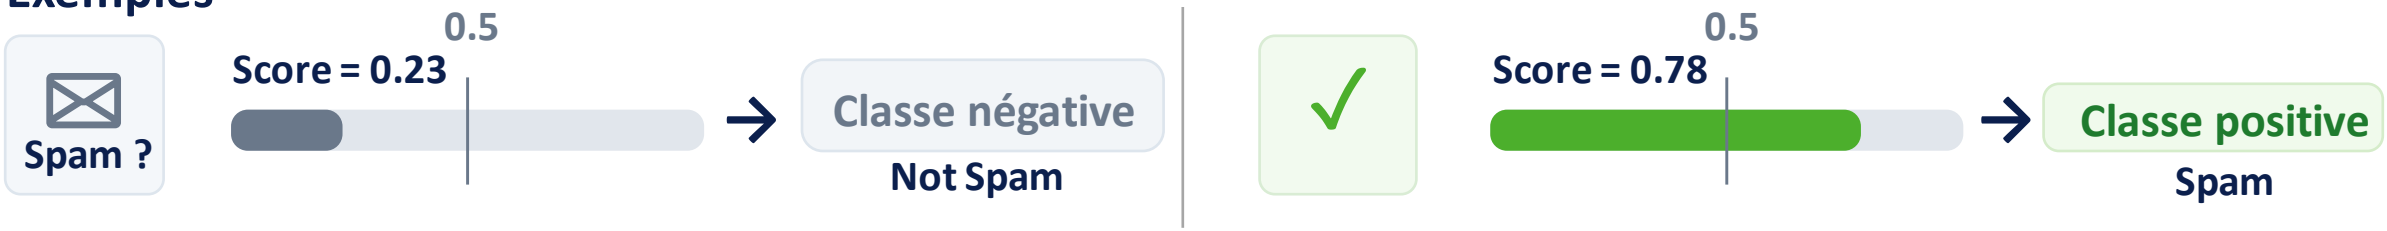


Règle de décision

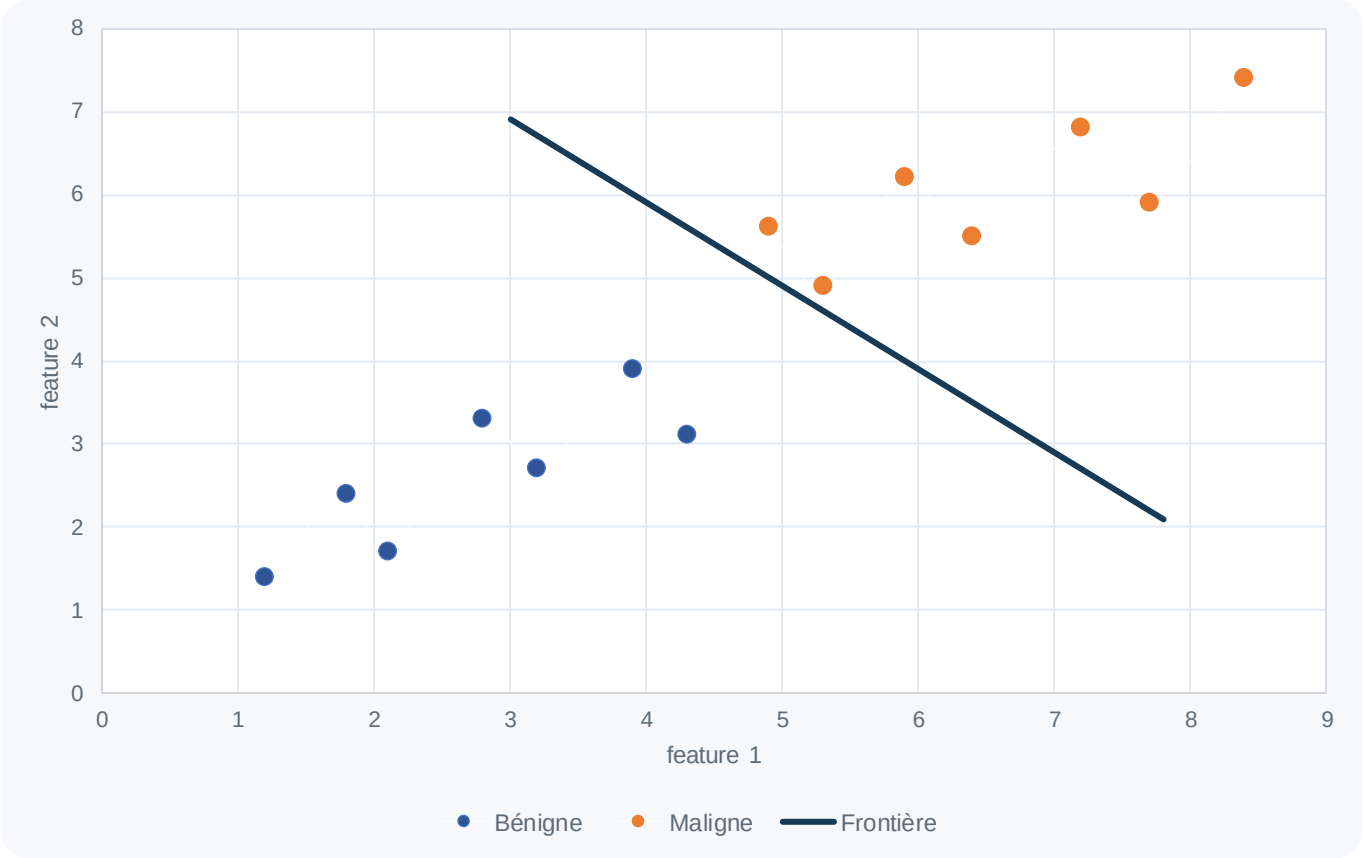
score ≥ seuil → classe positive ✓

score < seuil → classe négative ✗

Exemples



Frontière de décision

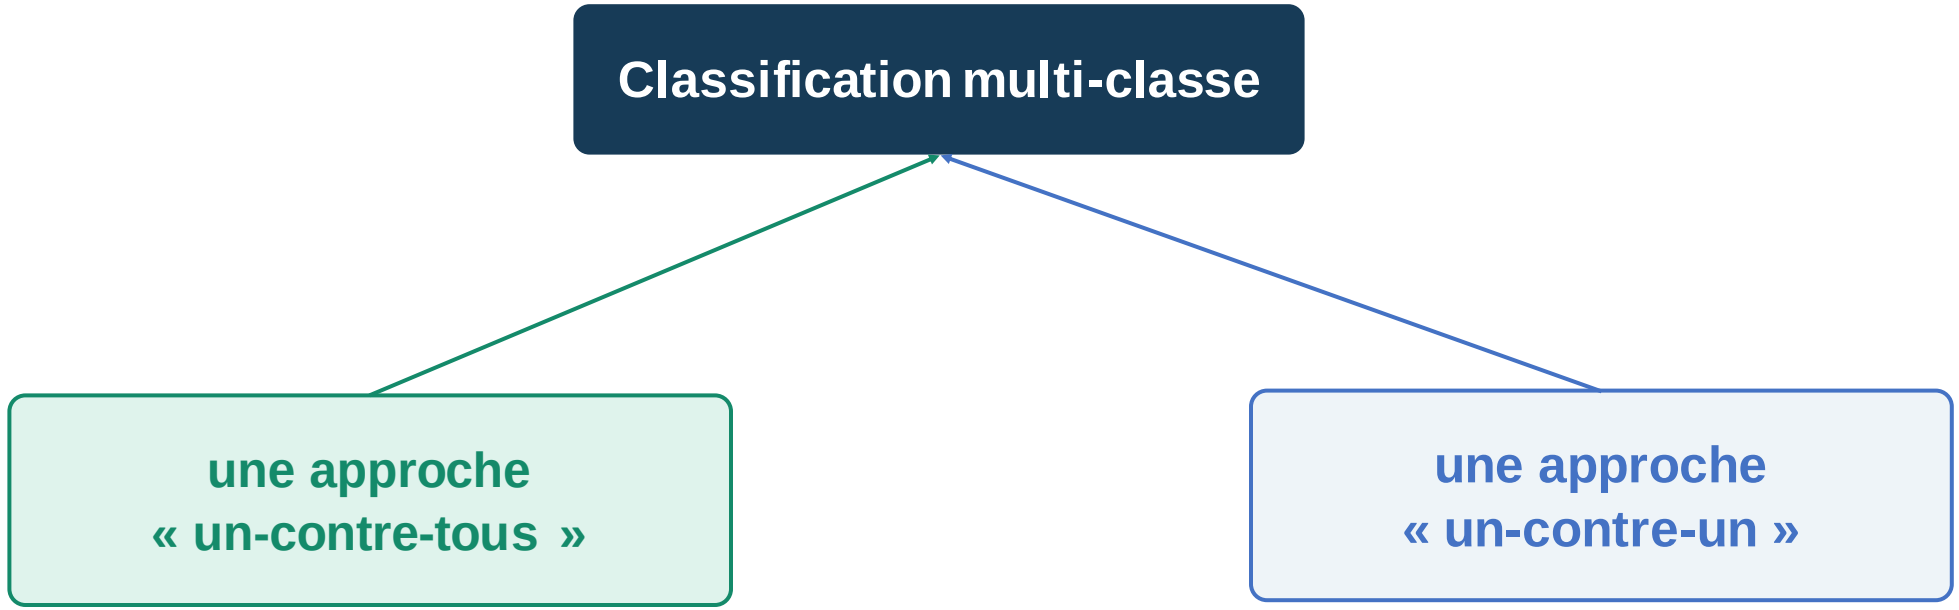


La frontière sépare **l'espace** des features en **zones de décision.**

- Chaque point représente une instance.
- La position vient de deux features.
- Le côté de la frontière donne la classe prédite.

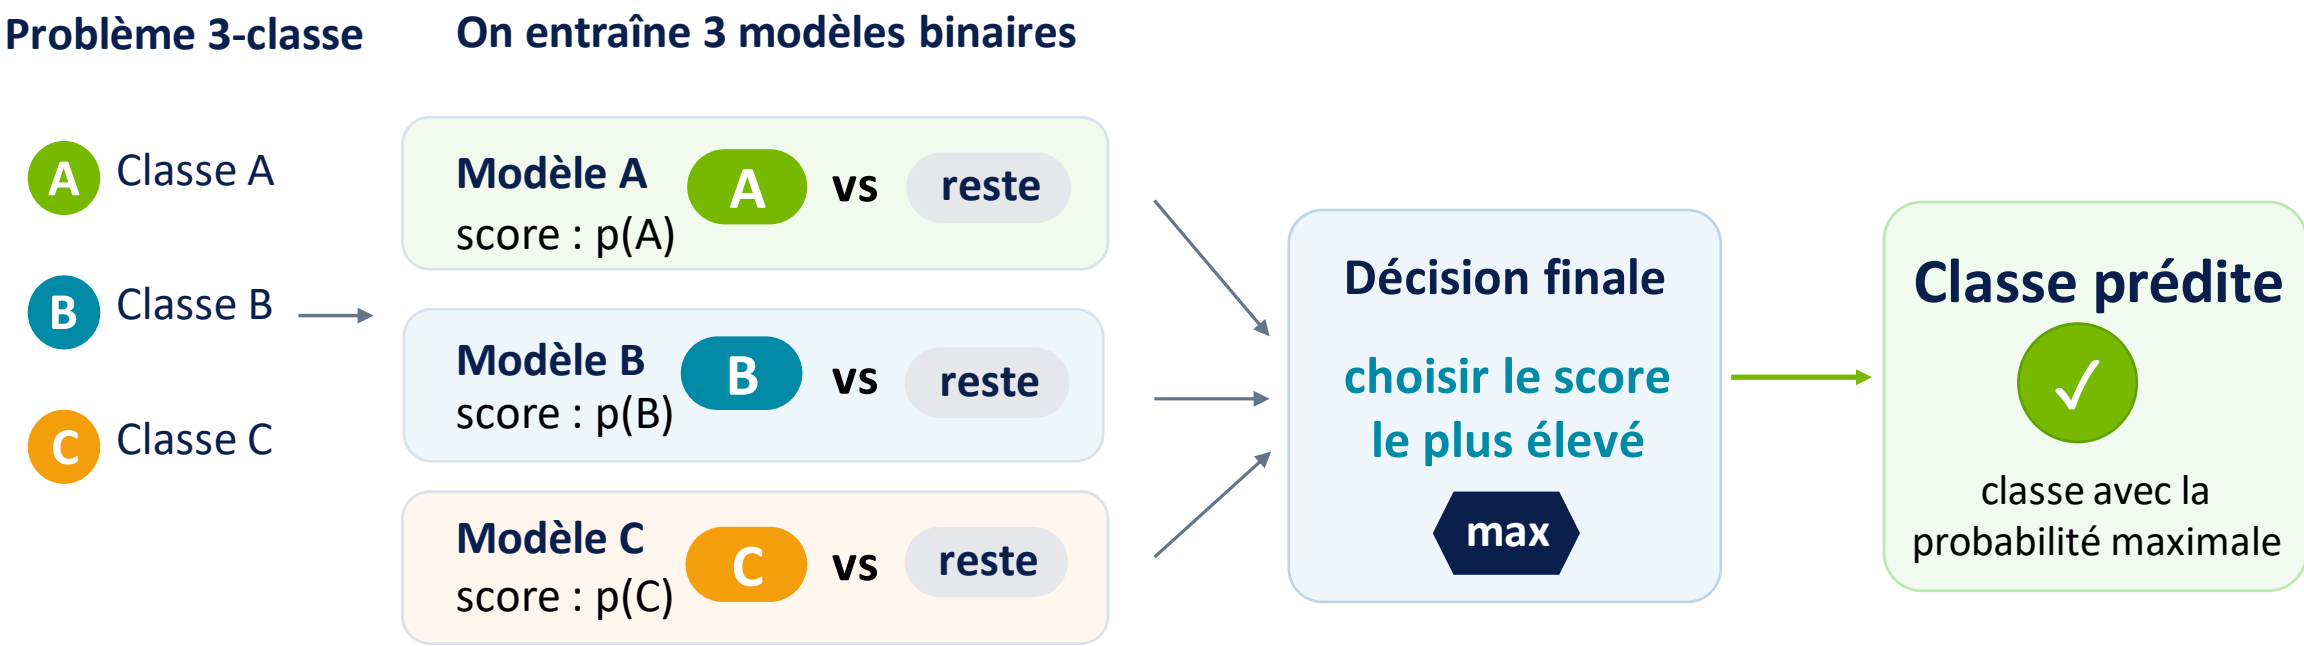
Classification multi-classe

Les algorithmes conçus initialement pour la classification binaire peuvent être adaptés pour traiter des problèmes de classification à N classes.



Un contre tous (One-vs-All)

Transformer un problème à **N classes** en **N décisions** binaires. chaque classifieur répond **« ma classe »** ou **« les autres »** ; la classe retenue est celle dont le score est **maximal**.



À retenir

N classes — problème initial → **N modèles binaires** — un par classe → **N frontières** — classe vs reste

Un contre un (One-vs-One)

Un **classifieur** pour **chaque paire**, puis un **vote** final.

1. 1 modèle pour chaque paire de classes
2. **Total : N(N−1)/2 modèles**
3. Chaque modèle donne un vote
4. **Classe finale = plus de votes**

Frontières de décision : N(N−1)/2

Exemple : 4 classes → 6 modèles

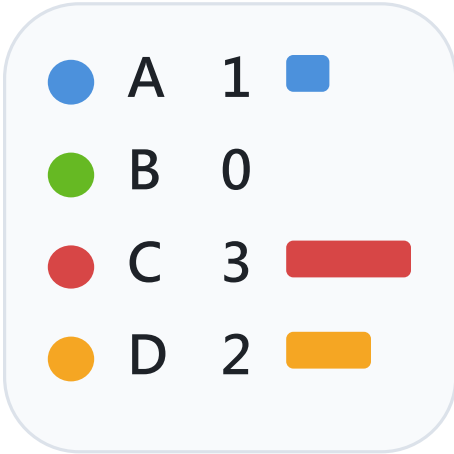
A B C D classes

Paires de modèles :

A vs B | A vs C | A vs D

B vs C | B vs D | C vs D

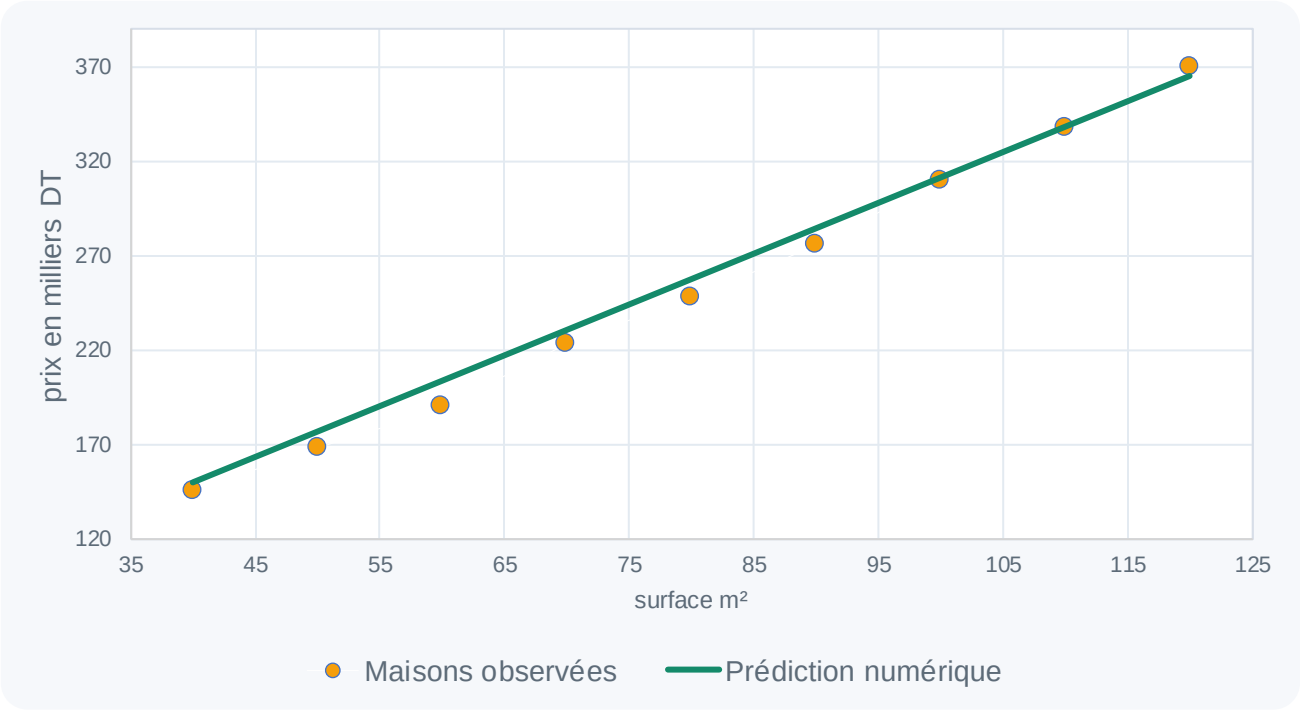
→ votes



Plus de votes → C classe finale

Notion générale de régression

La sortie recherchée est une valeur numérique continue.



Maison	350 000 DT
Température	28,4 °C
Patient	durée d'hospitalisation

Classification vs régression

Question	Classification	Régression
Sortie	Catégorie	Valeur numérique
Exemple médical	Maligne / Bénigne	Durée d'hospitalisation
Exemple immobilier	Zone de prix	Prix exact estimé
Erreur typique	Classe incorrecte	Écart numérique

Apprentissage non supervisé

À l'inverse, dans l'apprentissage **non supervisé**, le modèle est confronté à des données **non étiquetées** et doit **découvrir** des structures ou **des patterns** par lui-même.



Exemple

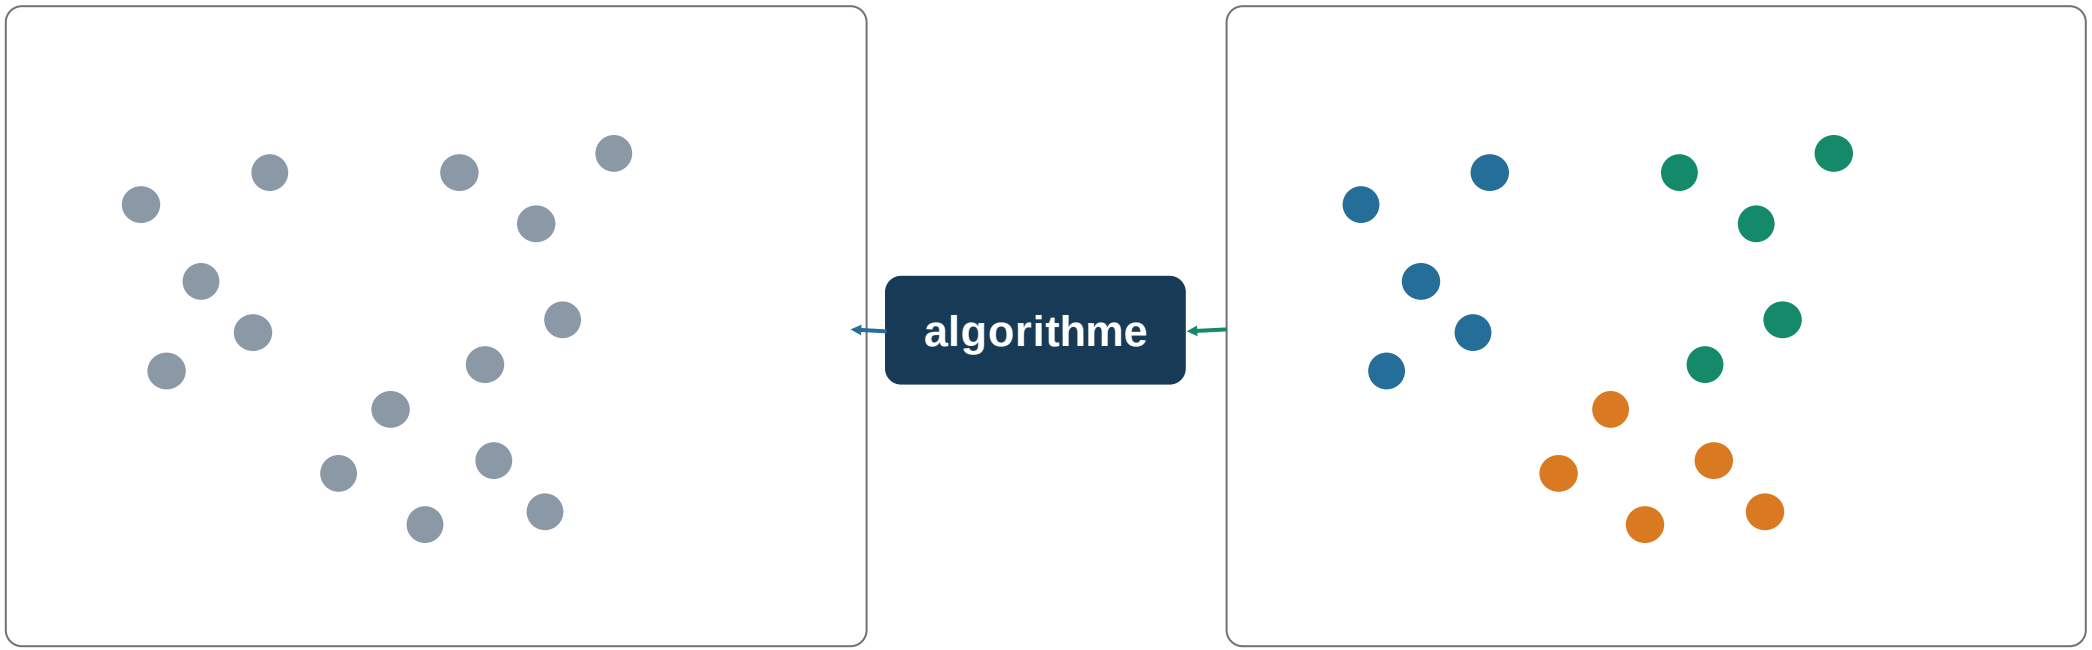
10 000 clients sans catégories initiales.
On cherche des profils naturellement similaires.

Ici, le modèle ne prédit pas une cible connue.
Il révèle une organisation plausible des données.

Clustering: avant et après

Avant: points non étiquetés

Après: groupes similaires



Le **clustering** découvre des groupes.
La **classification** utilise des classes déjà connues.

Supervisé et non supervisé

Supervisé	Non supervisé
Labels disponibles	Pas de labels
Prédire une cible	**Découvrir** une structure
Classification ou régression	Clustering principalement

Quel type d'apprentissage?

Question: On a 10 000 patients, on veut découvrir des profils.

Question: On a 10 000 patients, on veut les grouper selon leur maladie.

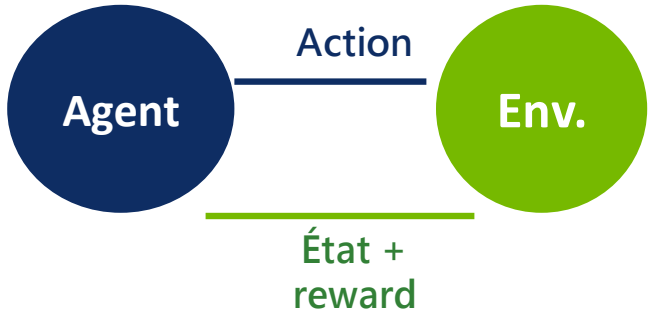
Apprentissage par renforcement

Un agent apprend par interaction pour choisir les actions les plus avantageuses.

1. **Agent** prend une action
2. **Environnement** réagit et change d'état
3. **Récompense** + bonus / − pénalité

Objectif : maximiser la récompense

La boucle d'apprentissage



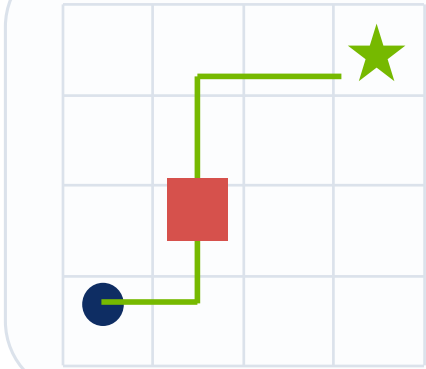
+ récompense

− pénalité

Il apprend une stratégie utile à long terme.

Exemple

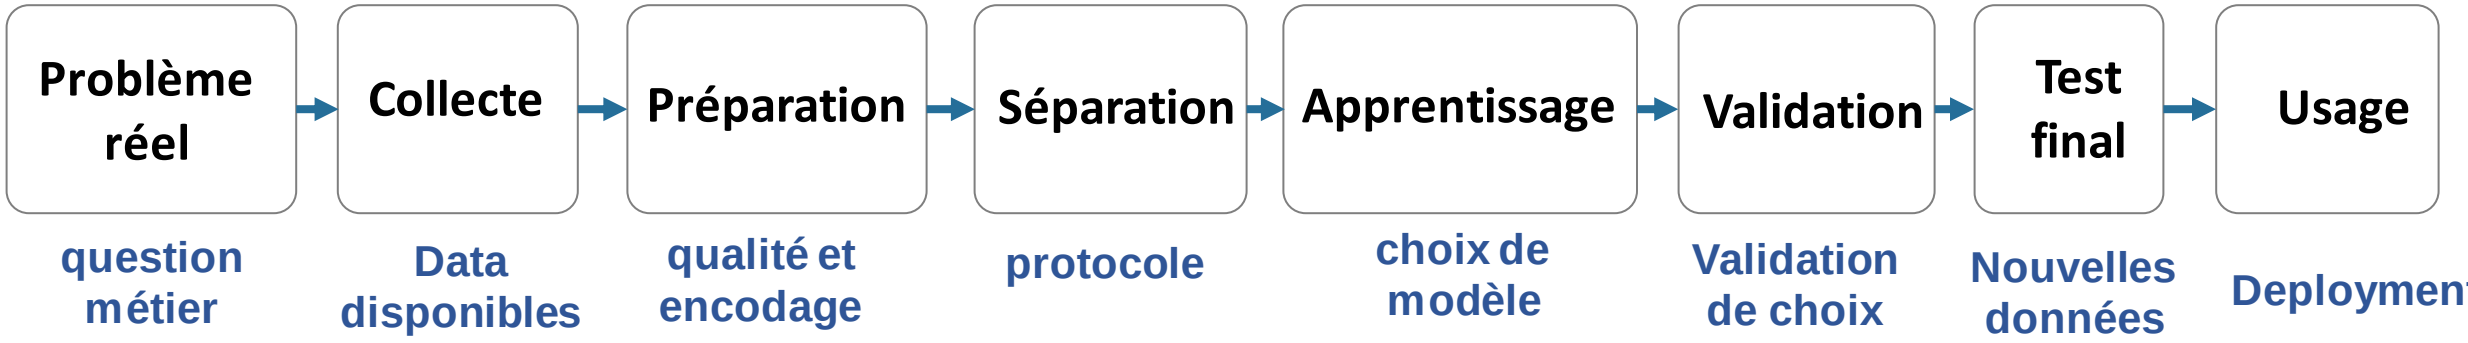
Robot dans une grille



But +1

Obstacle −1

Processus complet de Machine Learning



Le modèle ne doit jamais être jugé uniquement sur les données utilisées pour apprendre.

Séparation Train / Validation / Test

Exemple de découpage possible



Ces proportions ne sont pas une règle universelle.
Elles dépendent de la taille du dataset et du protocole.

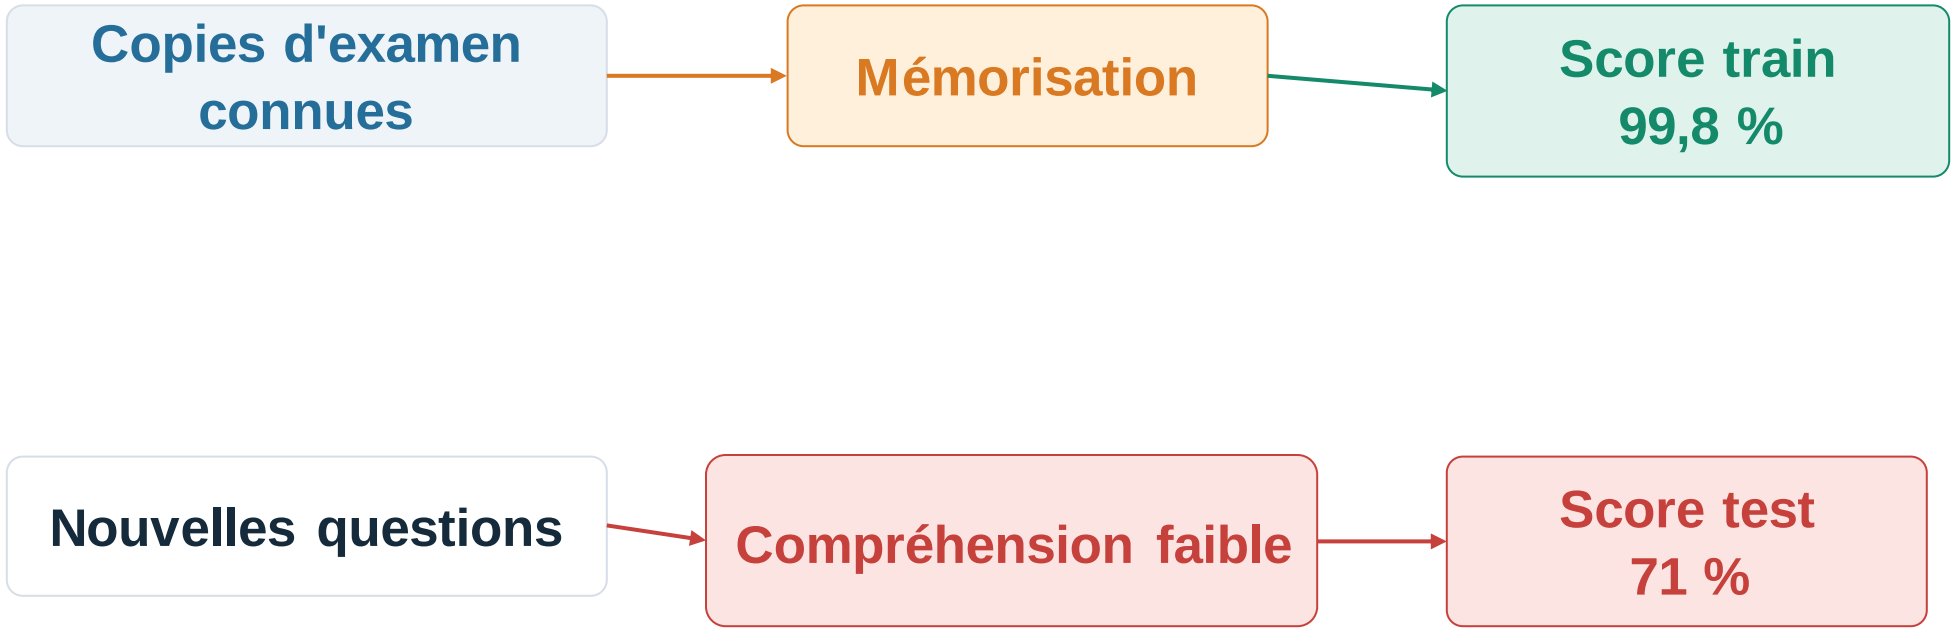
Rôles des trois ensembles

Training set	Validation set	Test set
Le modèle voit ces données. Il apprend ses paramètres.	On compare les configurations. On choisit les hyperparamètres.	On l'utilise à la fin. Il estime la performance future.

Métaphore académique

- ✓ Train = étudier
- ✓ Validation = examens blancs
- ✓ Test = examen final

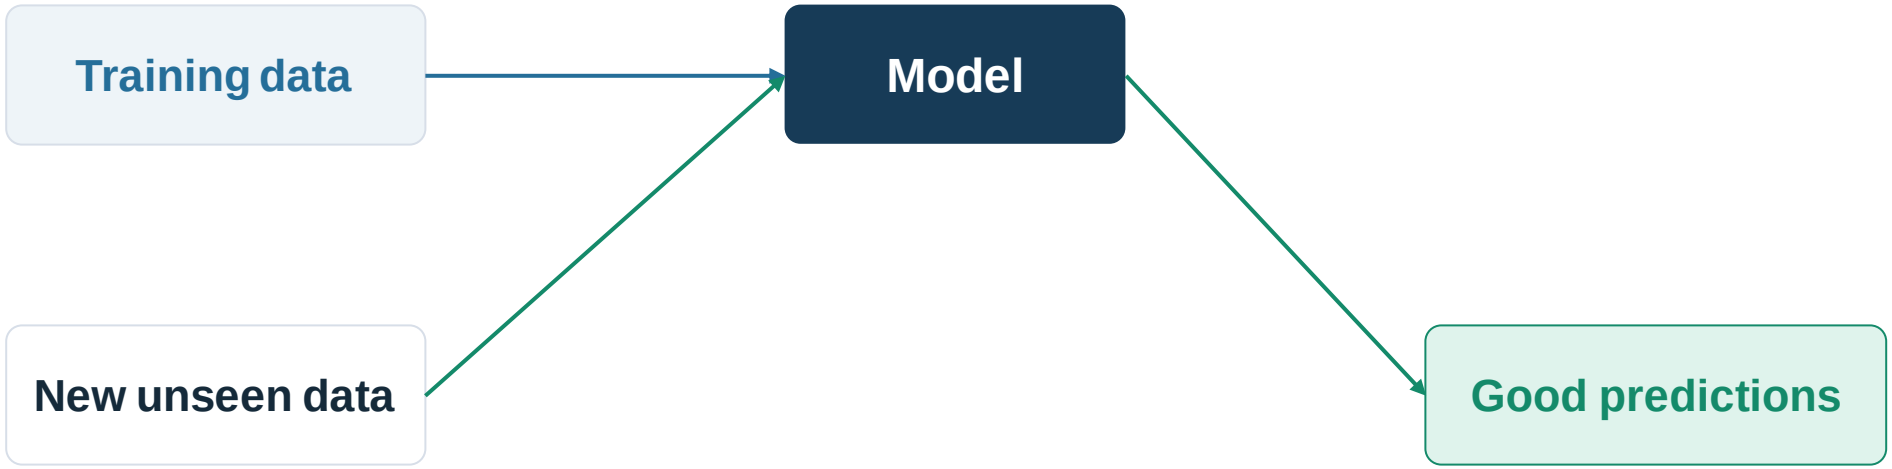
Pourquoi ne pas entraîner et tester sur les mêmes données ?



Un bon protocole empêche le modèle de confondre apprentissage et mémorisation.

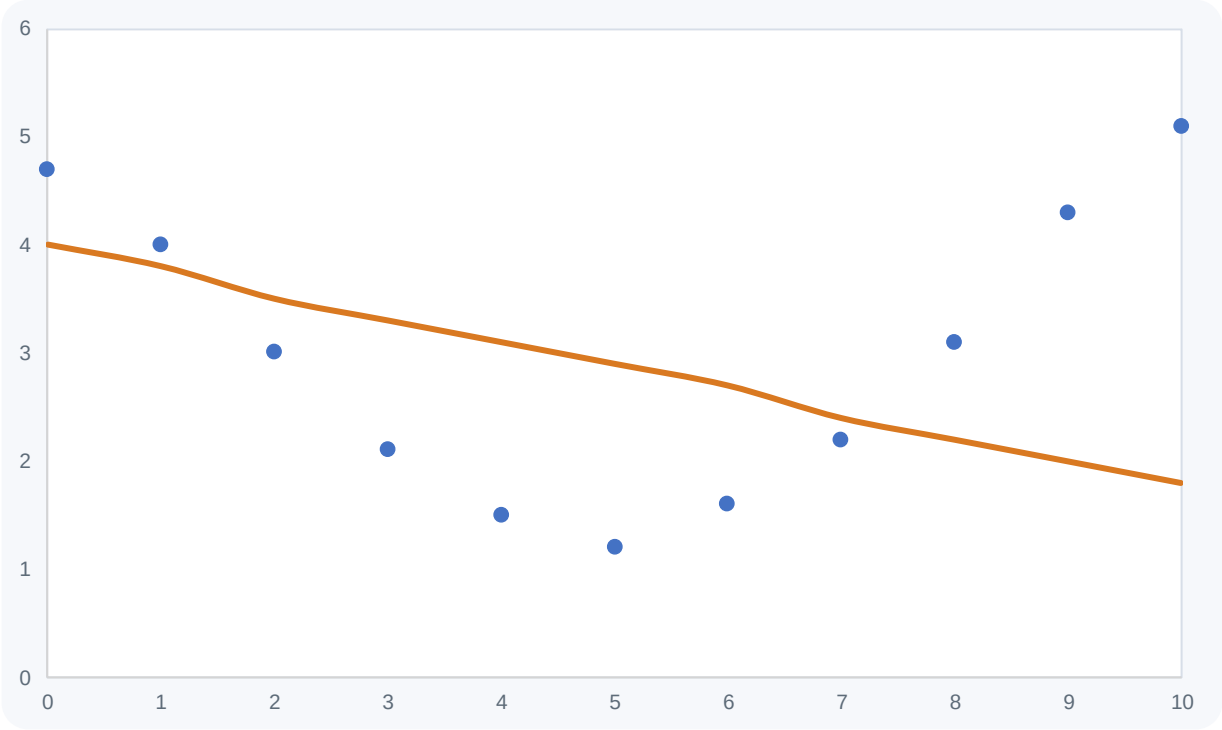
Généralisation

Un modèle généralise lorsqu'il fonctionne sur des données jamais vues pendant l'entraînement.



Objectif réel: bonnes performances sur de nouvelles observations du même problème.

Underfitting



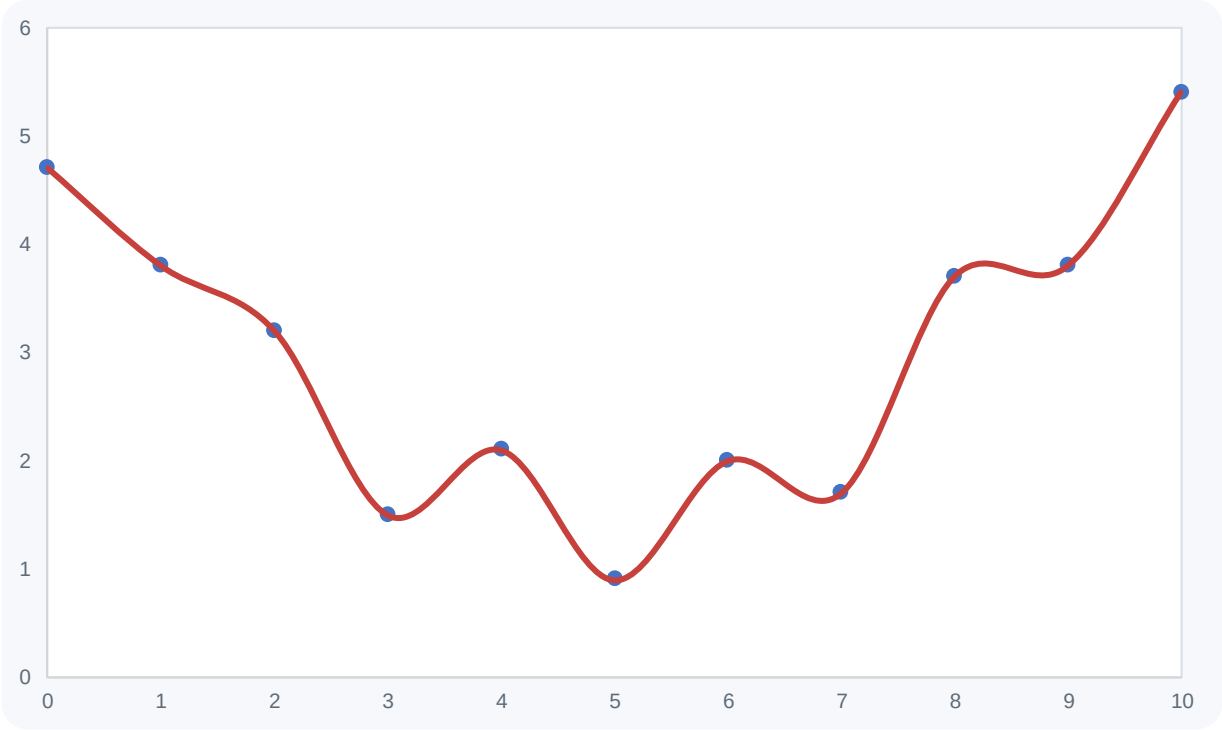
Modèle trop simple pour capturer la structure des données.

Training error: élevée
Validation/Test error: élevée

- Modèle trop contraint.
- Features insuffisantes.
- Apprentissage trop court.

Ajouter des données ne corrige pas toujours un modèle incapable d'exprimer la structure.

Overfitting



Le modèle apprend trop précisément le train, y compris le bruit.

Training error: très faible
Validation/Test error: élevée

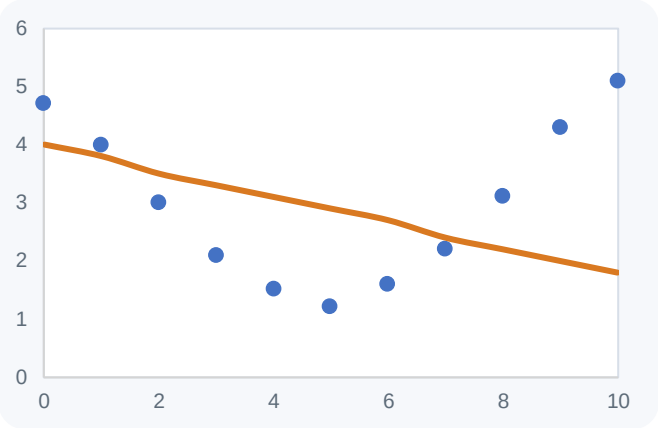
Analogie

Mémoriser exactement un ancien examen donne un bon score seulement si les questions reviennent identiques.

Underfitting, bon compromis, overfitting

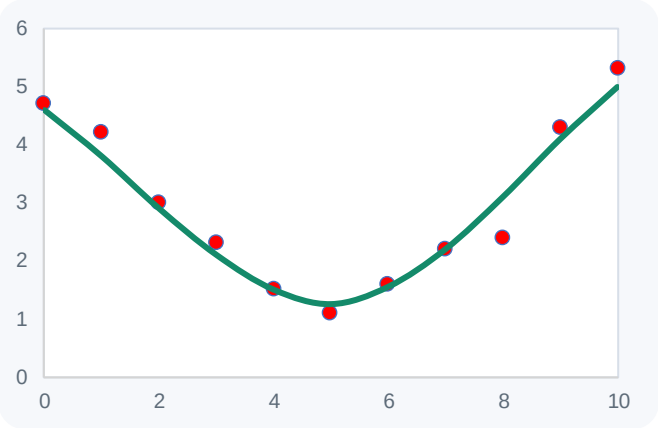
Underfitting

modèle trop simple



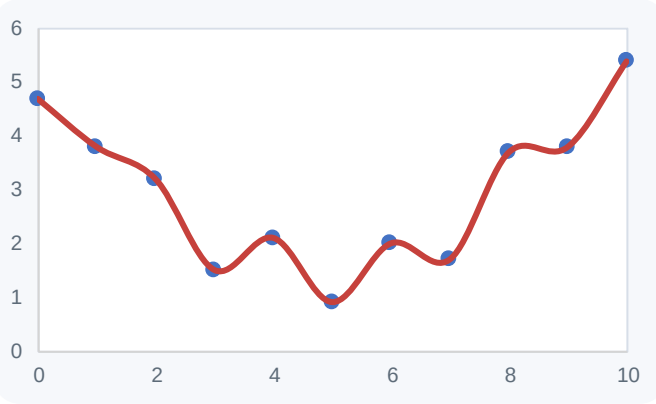
Bon compromis

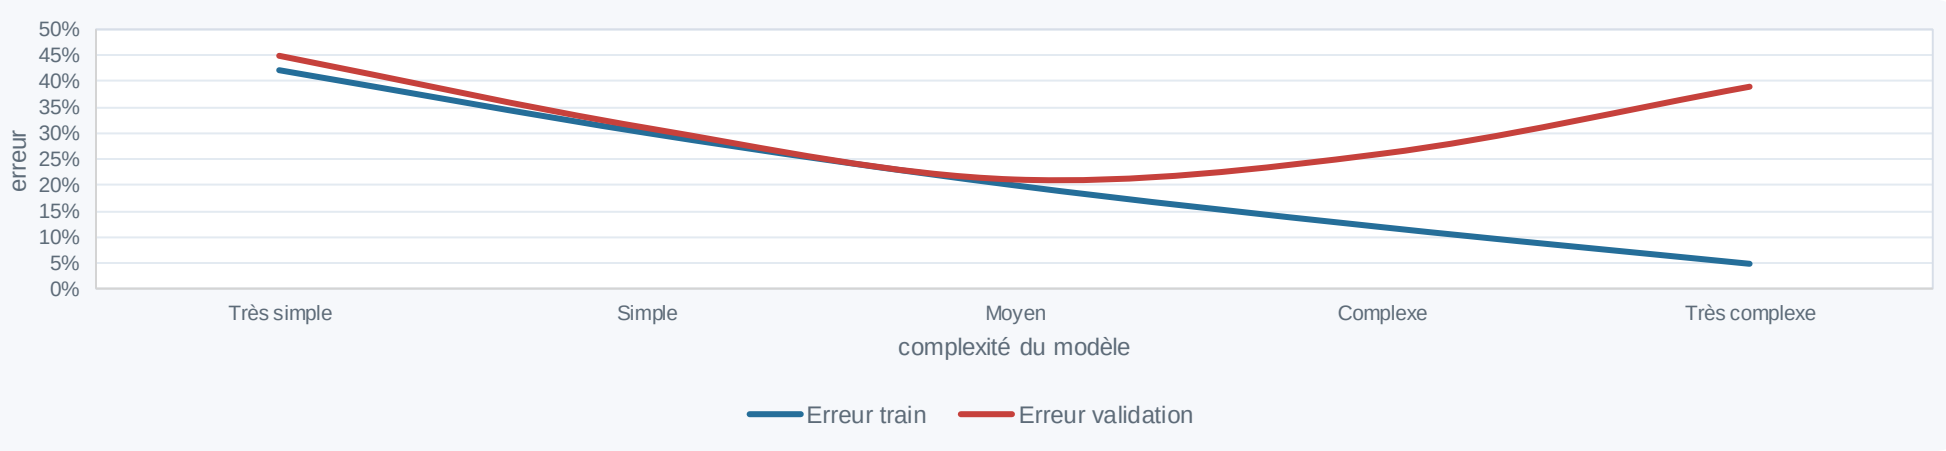
structure correctement apprise



Overfitting

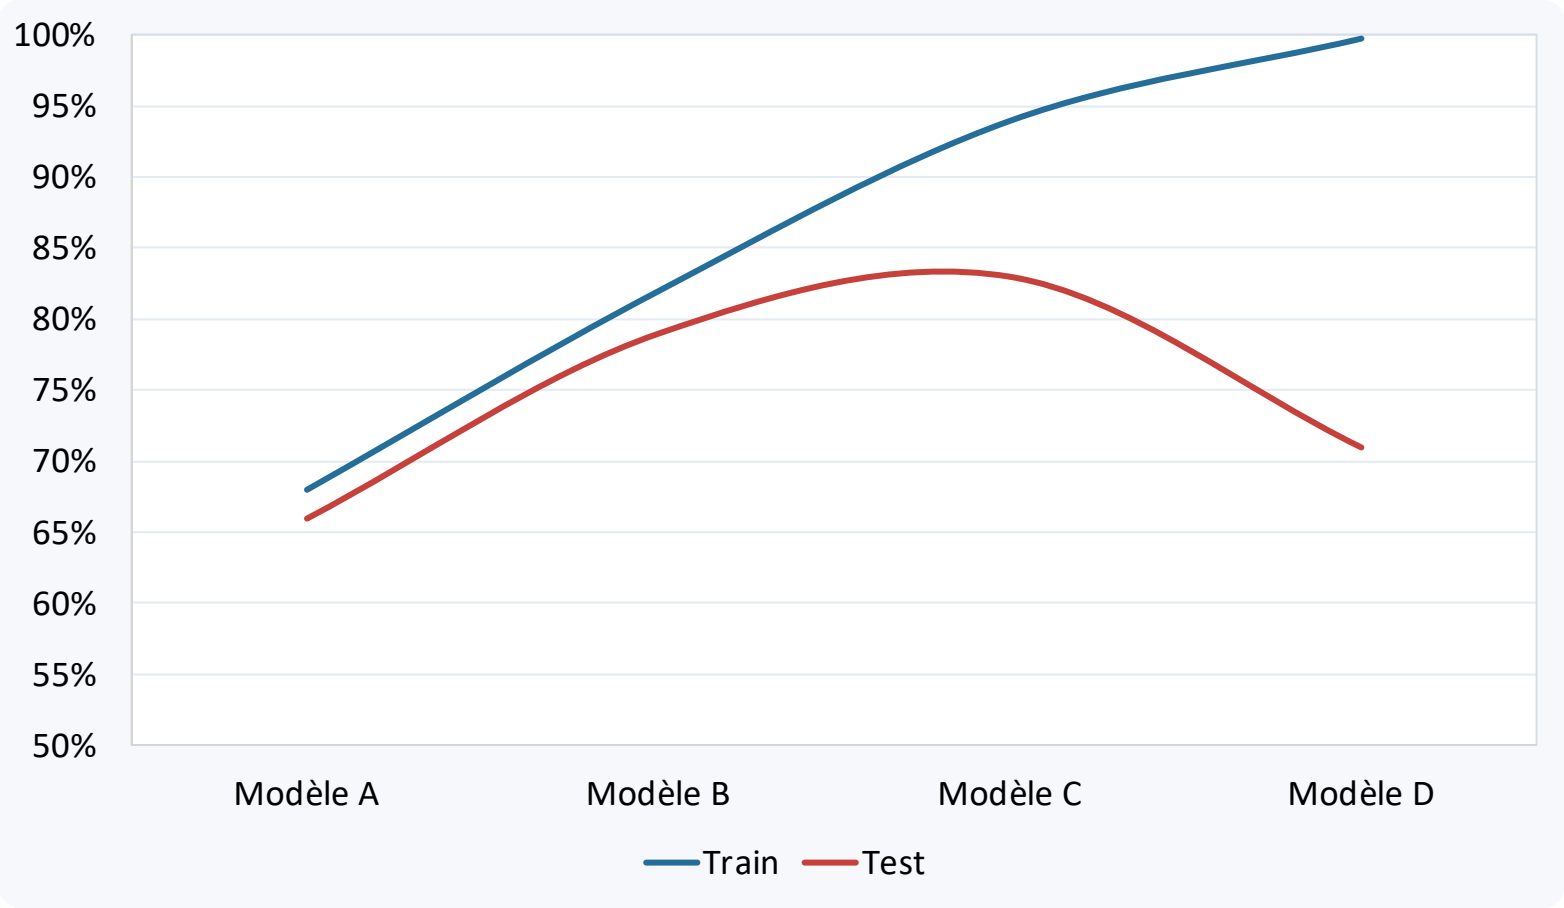
modèle trop complexe





Complexité du modèle ↑

Performance train et performance test



Train = performance sur les données vues

Test = approximation de la performance future