Année scolaire
2026 - 2027

Chapitre 2

k-Nearest Neighbors

Distance → Neighbors → Vote → Prediction

Enseignante :

Dr. Ing. Ones Sidhom

Ambassadrice NVIDIA & Instructrice Certifiée

Enseignante-Chercheuse en IA & Science des Données

Définition

“Dis moi qui sont tes voisins, je te dirais qui tu es...”

- **k-NN** est un algorithme d’apprentissage **supervisé** basé sur la notion de **proximité** entre les observations.
- Il repose sur l’hypothèse suivante :

Des observations proches dans l’espace des caractéristiques ont généralement des comportements similaires

Caractéristiques essentielles

- **Non paramétrique** : il ne suppose pas une forme prédéfinie du modèle.
- **Instance-based learning** : les données d’apprentissage servent directement de référence.
- **Lazy learning** : il ne construit pas de modèle explicite pendant l’apprentissage.
- Utilisable pour la **classification** et la **régression**.
- Son comportement dépend fortement de la **notion de distance** et de la représentation des caractéristiques.

Structure des données dans k-NN

ID	Taille tumeur	Texture	Âge	Classe
1	1.2	0.31	42	Bénigne
2	4.7	0.82	61	Maligne
3	1.8	0.44	39	Bénigne
4	5.2	0.76	58	Maligne

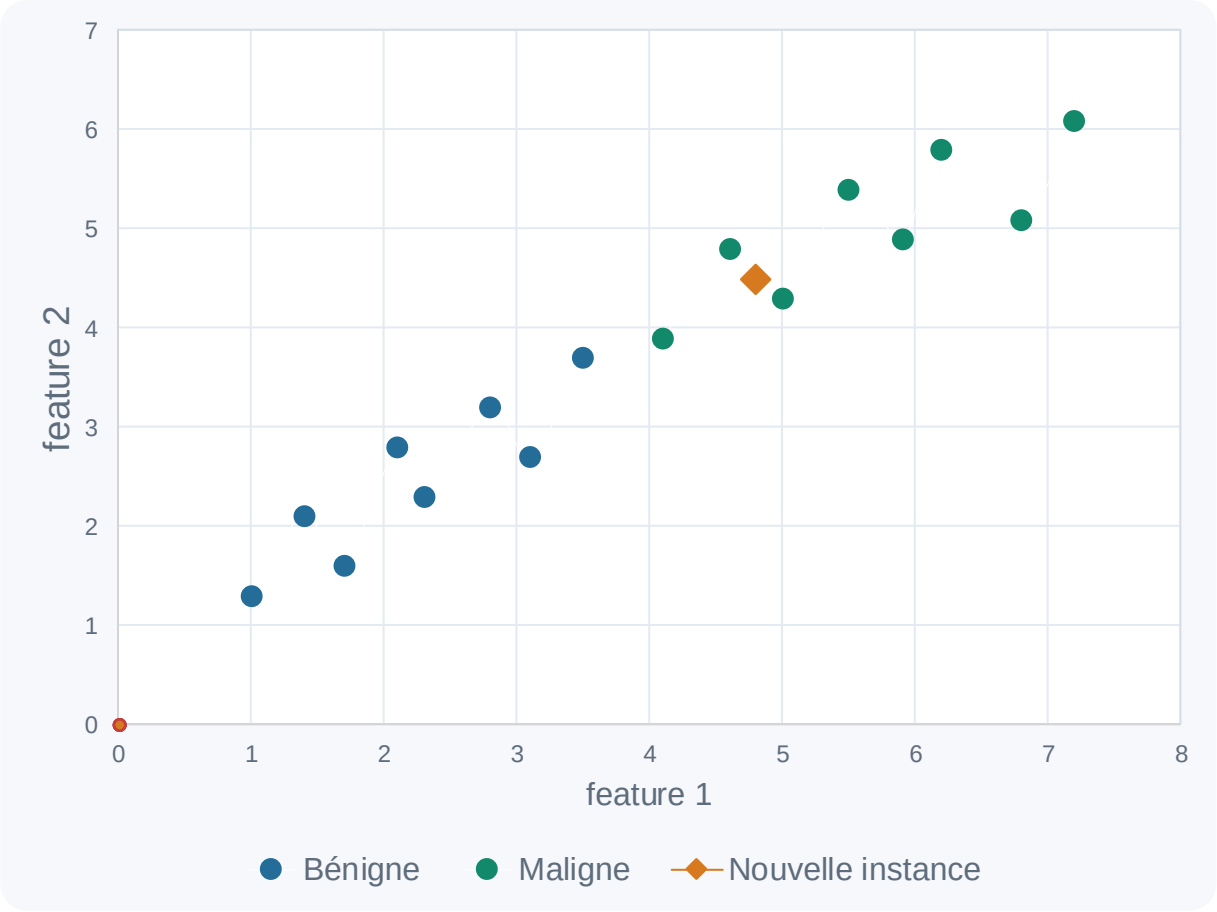
Une ligne = une instance

Une colonne = une feature

Le label = la classe à prédire

Dans k-NN, les features servent directement à calculer les distances.

Classification par voisinage



Pour prédire le point orange, on regarde les exemples étiquetés les plus proches.

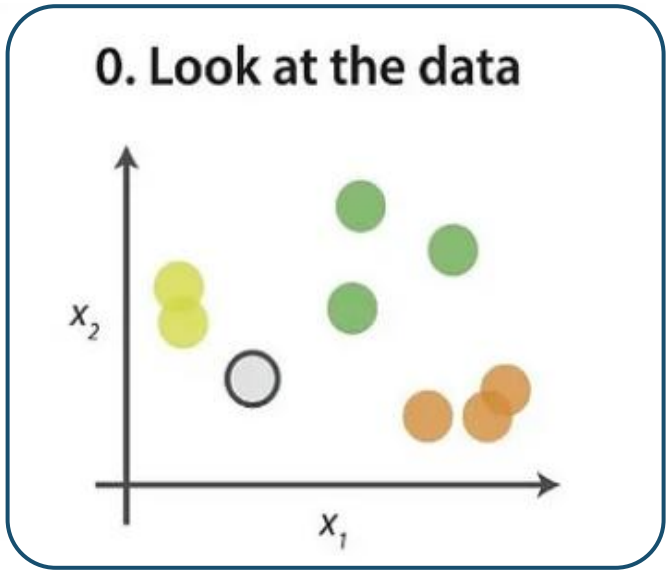
- distance aux observations connues
- sélection des voisins
- classe majoritaire
- prédiction finale

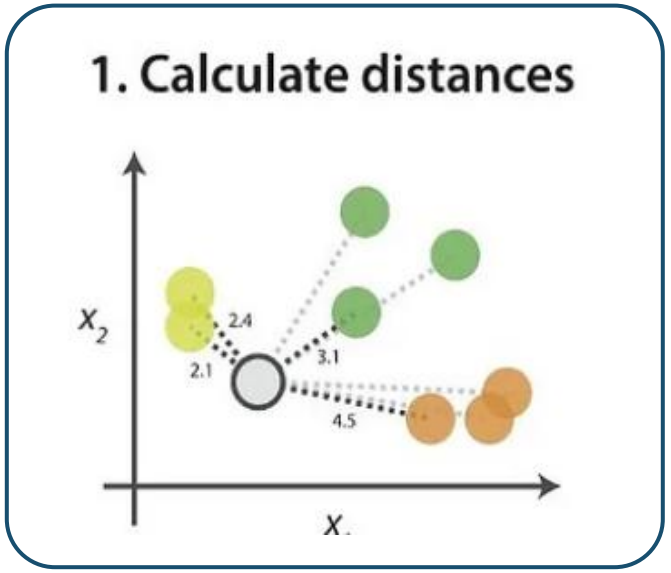
Classification par voisinage

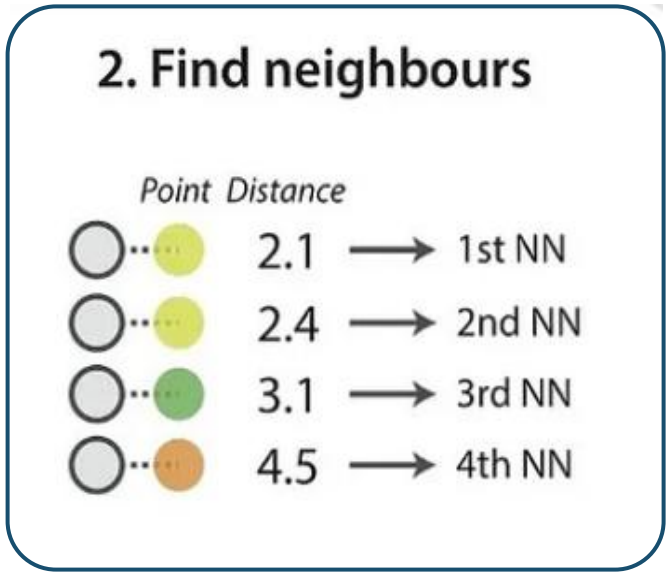
L'algorithme des K plus proches voisins est l'une des plus simples de tous les algorithmes de Machine Learning supervisé :

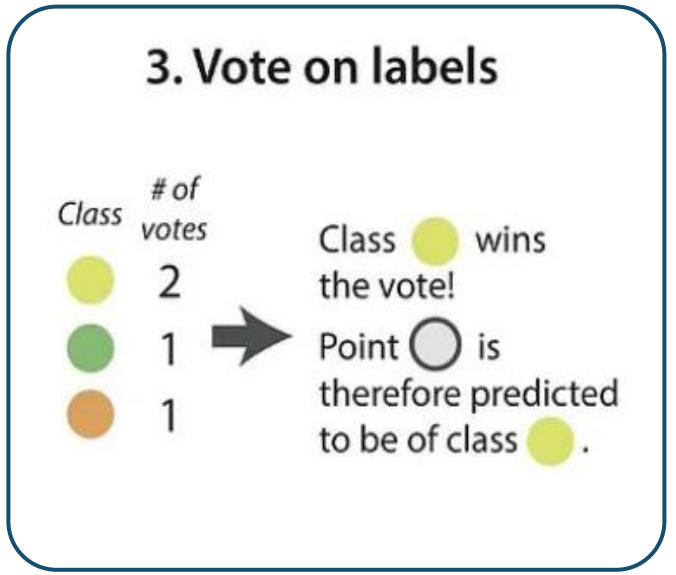
1. Sélectionnez le nombre K de voisins.
2. Calculez la distance du point non classifié aux autres points.
3. Prenez les K voisins les plus proches selon la distance calculée.
4. Parmi ces K voisins, comptez le nombre de points appartenant à chaque catégorie.
5. Attribuez le nouveau point à la catégorie la plus présente parmis ces K voisins.

Classification par voisinage

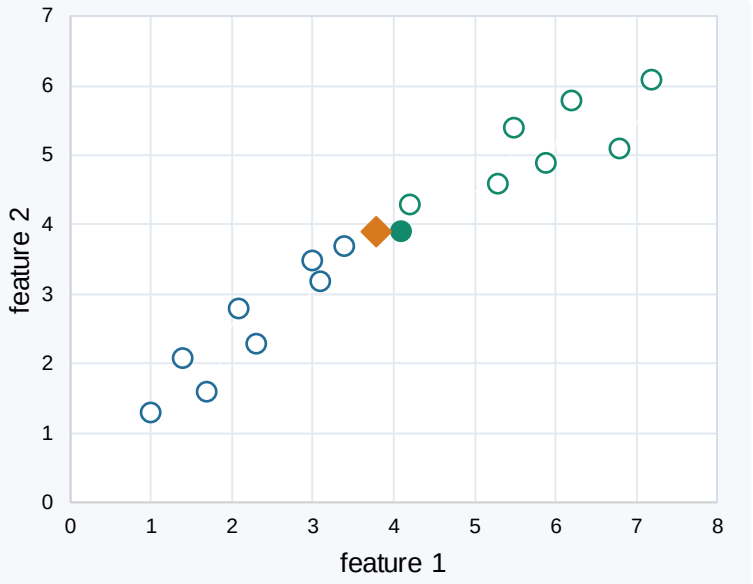






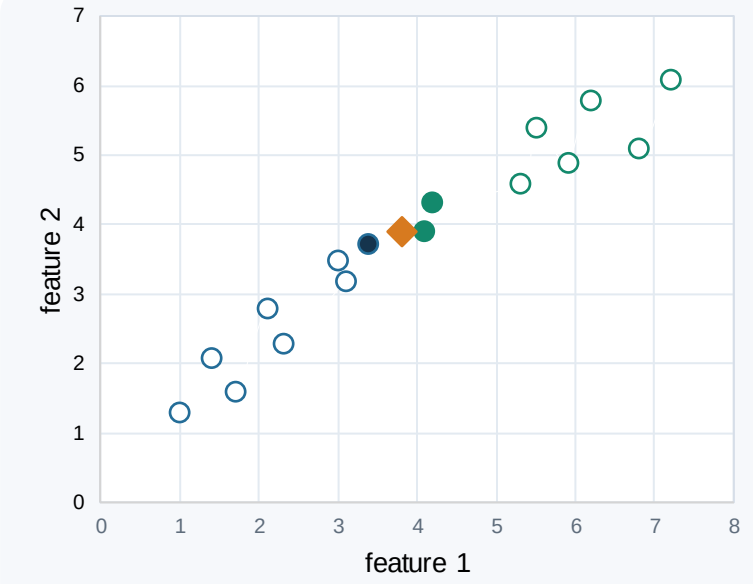


Effet de k sur le vote



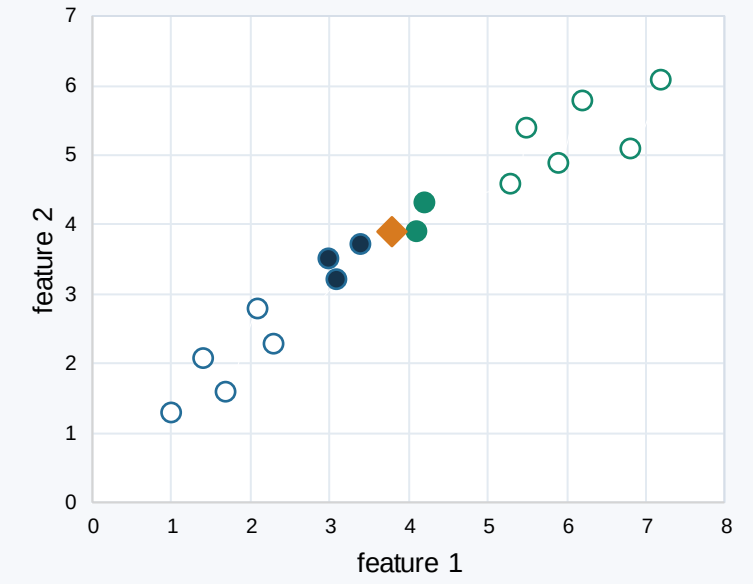
k = 1

1 voisin proche
classe verte



k = 3

2 verts, 1 bleu
classe verte



k = 5

3 bleus, 2 verts
classe bleue

Changer k change la taille du voisinage et peut changer la classe prédite.

Calcul de similarité

- K-NN a besoin d'une fonction de calcul de distance entre deux observations.
- Plus deux points sont proches l'un de l'autre, plus ils sont similaires et vice versa.
- Il existe plusieurs fonctions de calcul de distance :

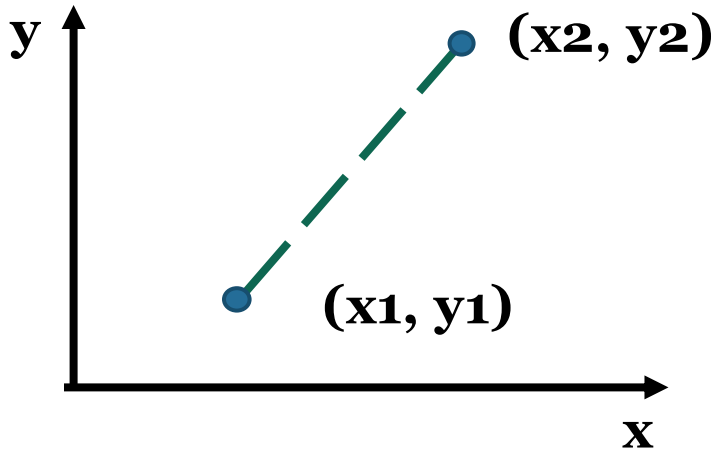
  - La distance euclidienne
  - La distance de Manhattan
  - La distance de Minkowski
  - La distance Jaccard
  - La distance de Hamming

Calcul de similarité

1- Distance euclidienne

- Distance qui calcule la racine carrée de la somme des différences carrées entre les coordonnées de deux points.

$$d(X,Y) = \sqrt{\sum_{i=1}^{n}(y_i - x_i)^2}$$



Exemple:

$$A = (2,3), \qquad B = (5,7)$$

$$d(A,B) = \sqrt{(5-2)^2 + (7-3)^2} = \sqrt{9+16} = 5$$

Quand l'utiliser ?

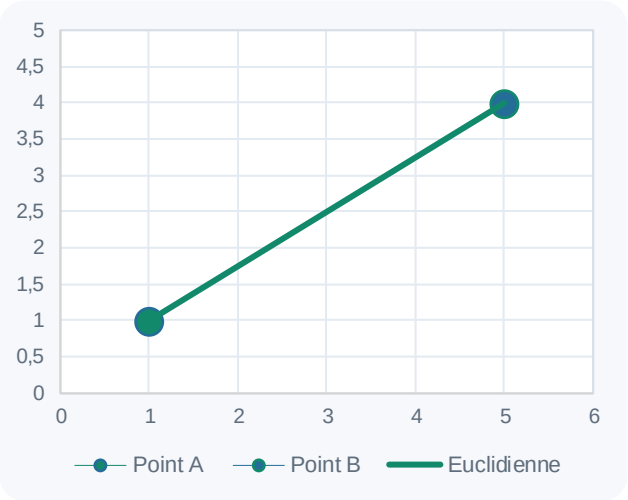
- les variables sont **numériques continues**
- les caractéristiques sont sur des **échelles comparables**
- les données ne contiennent pas trop de valeurs aberrantes.

Calcul de similarité

1- Distance euclidienne

Exercice:

Feature	Point A	Point B	
x1	1	5	
x2	1	4	
Total			

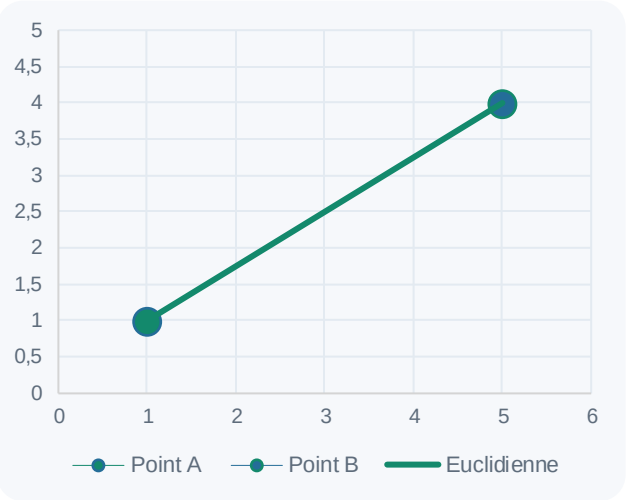


Calcul de similarité

1- Distance euclidienne

Exercice:

Feature	Point A	Point B	
x1	1	5	
x2	1	4	
Total			**5**



d(A, B) = sqrt(16 + 9) = 5

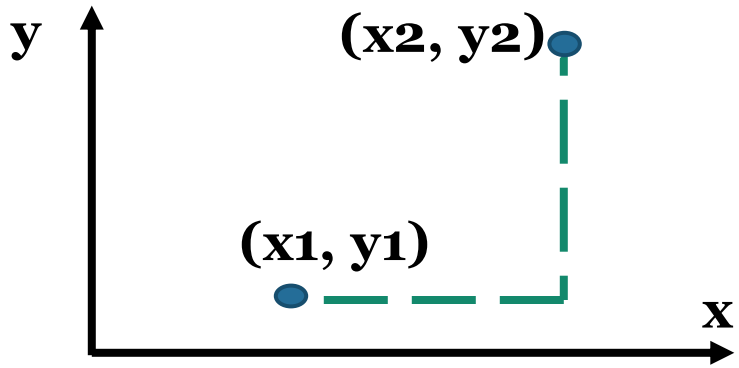
Plus la distance est faible, plus les deux points sont proches selon les features choisies.

Calcul de similarité

2- Distance Manhattan

- La distance de Manhattan mesure la distance entre deux points en suivant les bords d'un hypercube dans un espace multidimensionnel.

$$\text{Manhattan Distance}\,(p,q) = \sum_{i=1}^{n} |p_i - q_i|$$



Quand l'utiliser ?

- préférée pour les données discrètes ou catégorielles.
- Si les caractéristiques ont des relations non linéaires ou indépendantes.
- Souvent utile avec des données de **plus grande dimension**

Le rôle du paramètre k

k indique combien de voisins participent à la décision.

k petit	k intermédiaire	k grand
décision très locale	souvent bon compromis	décision plus lissée

k = 1: décision très locale

- sensible au bruit
- frontière souvent irrégulière
- risque d'overfitting

k = 1 peut mémoriser des détails locaux non généralisables.

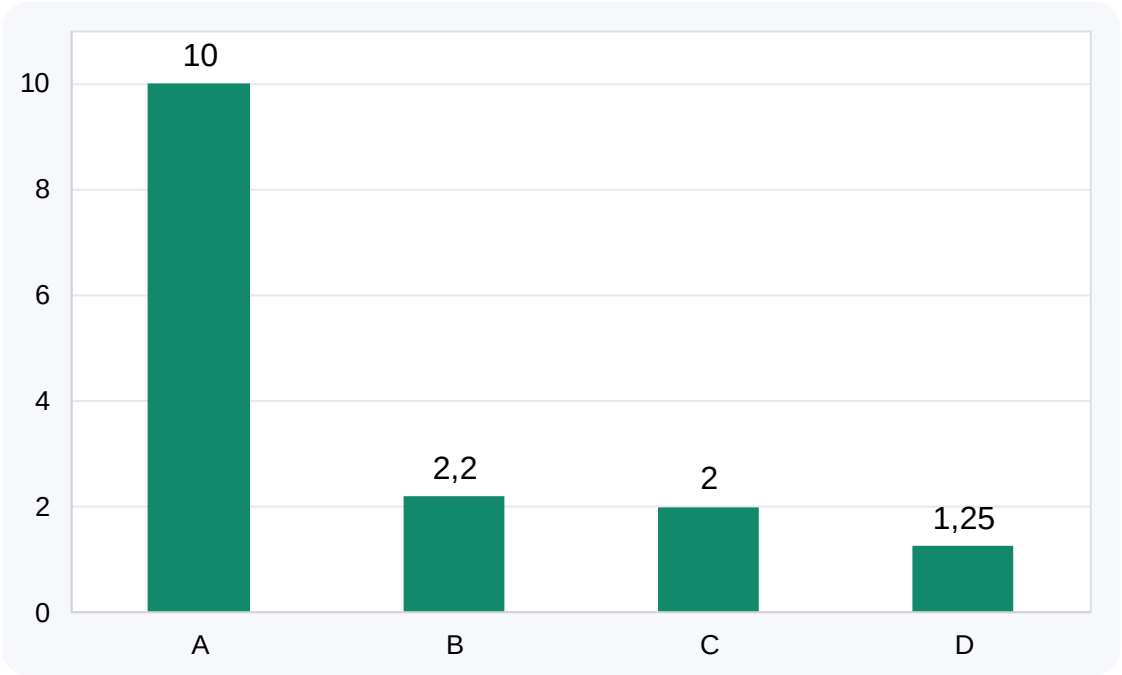
k grand: décision plus lissée

- moins sensible à un point bruité
- frontière plus régulière
- risque d'underfitting si k devient trop grand

Un grand k peut ignorer une structure locale réelle.

Le rôle du paramètre k

Voisin	Distance	Classe	Poids intuitif
A	0.10	Maligne	très fort
B	0.45	Bénigne	moyen
C	0.50	Bénigne	moyen
D	0.80	Bénigne	faible



poids proportionnel à 1 / distance

Les voisins les plus proches peuvent peser davantage que les voisins plus éloignés.

k-NN et normalisation

Feature	Ordre de grandeur
âge	18 à 70
revenu	5 000 à 100 000

Sans normalisation

- revenu domine la distance
- âge pèse peu
- voisins biaisés par l'échelle
- prédictions trompeuses



k-NN repose directement sur les distances: il est très sensible au scaling.

k-NN et normalisation

Feature	Ordre de grandeur
âge	18 à 70
revenu	5 000 à 100 000

Sans normalisation

- revenu domine la distance
- âge pèse peu
- voisins biaisés par l'échelle
- prédictions trompeuses

Avec normalisation

- variables comparables
- distance plus équilibrée
- voisinage plus cohérent
- choix des features encore nécessaire

k-NN repose directement sur les distances: il est très sensible au scaling.

Normalisation et standardisation

Normalisation Min-Max:

Ramène les valeurs dans un intervalle, généralement : [0 , 1]

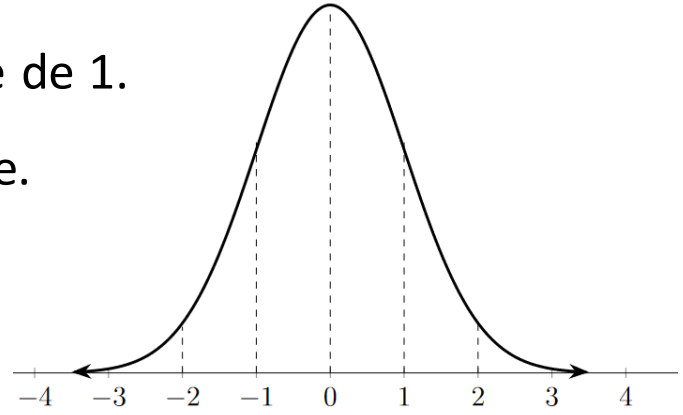
$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

À utiliser quand :

- on veut des valeurs **bornées entre 0 et 1** ;
- les variables ont des échelles très différentes ;
- **Attention :** sensible aux valeurs aberrantes.

Standardisation — Z-score

- La moyenne devient proche de 0.
- L'écart-type devient proche de 1.
- La variable n'est pas bornée.



$$x' = \frac{x - \mu}{\sigma}$$

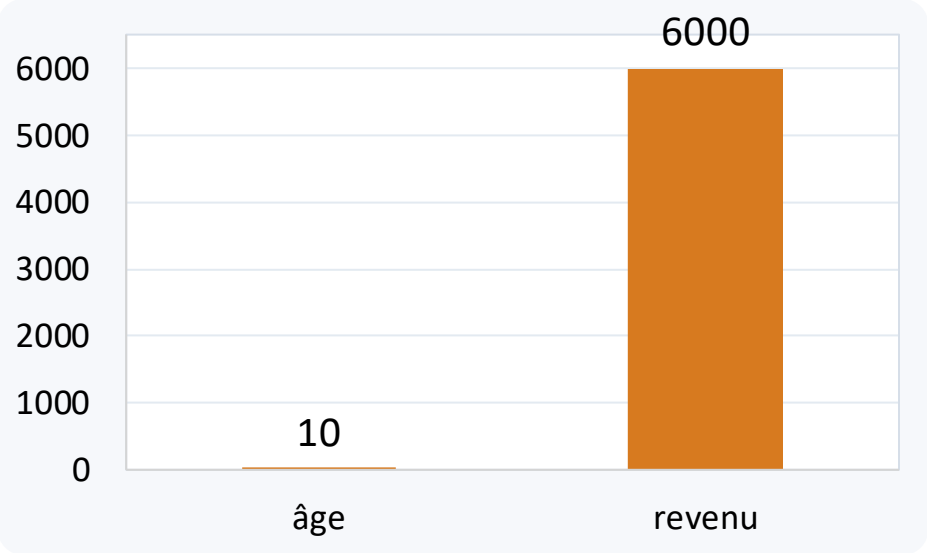
- on veut des variables sur une échelle comparable ;
- les données ne doivent pas obligatoirement être limitées à [0 , 1];

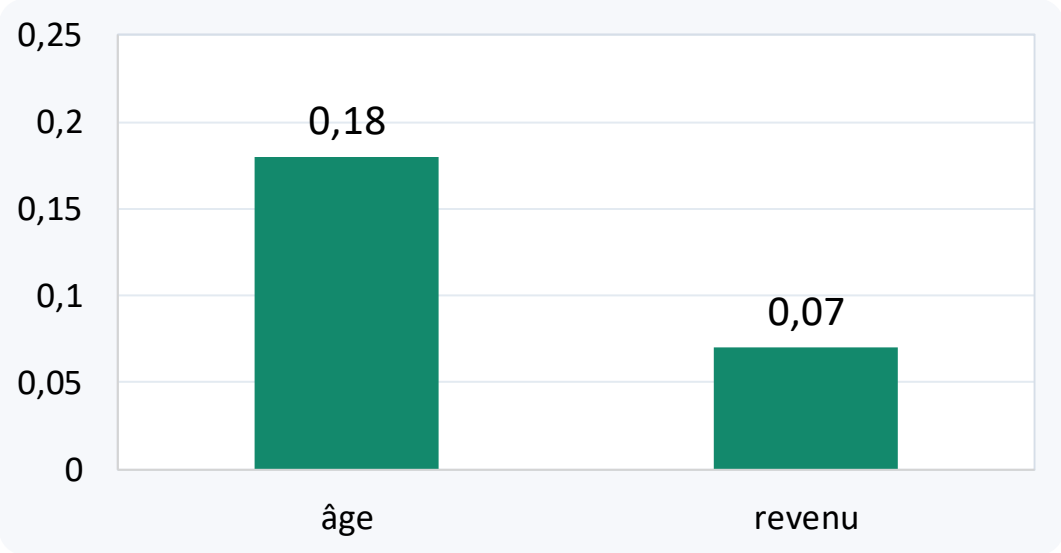
L'**écart-type** mesure à quel point les valeurs sont **éloignées ou dispersées autour de la moyenne**.

k-NN et normalisation

Variable	Client A	Client B	Écart brut
âge	25	35	10
revenu	20000	26000	6000

Variable	Client A	Client B	Écart scaled
âge	0.20	0.38	0.18
revenu	0.16	0.23	0.07





Scaler ne rend pas les features bonnes: il rend leur comparaison numérique plus raisonnable.

k-NN en régression

Nouvelle instance > k voisins > Valeurs numériques > Moyenne > Prédiction

Voisin	Distance	Prix maison
1	0.15	180
2	0.28	190
3	0.34	200

Prédiction = (180 + 190 + 200) / 3 = 190

En classification on vote. En régression on moyenne les valeurs des voisins.

Avantages de k-NN

Avantage	Pourquoi c'est utile
Simple à comprendre	la décision se lit à partir des voisins
Intuitif	fondé sur la similarité locale
Non paramétrique	pas de forme globale imposée
Bonne baseline	rapide à expliquer et à tester

Limites de k-NN

Limite	Conséquence
Distance mal choisie	voisins peu pertinents
Scaling oublié	variable dominante
Variables inutiles	bruit dans le voisinage
Grande dimension	proximité moins informative
Grand dataset	prédiction coûteuse
k trop petit	sensibilité au bruit
k trop grand	décision trop lissée

Coût computationnel

Étape	Coût intuitif	Pourquoi
Entraînement	faible	stockage des données
Prédiction	plus coûteux	distances vers beaucoup d'exemples
Mémoire	potentiellement importante	dataset conservé

Accélérer la recherche des voisins

Dataset complet > Index spatial > Recherche plus rapide > Voisins candidats

KD-tree

Ball-tree

Approximate NN

utile pour accélérer la prédiction

efficacité dépend de la dimension

approximation possible si le dataset est très grand

Ces techniques aident le calcul, mais ne corrigent pas une mauvaise représentation.